SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU

FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Sveučilišni diplomski studij računarstva

Obrada slike i računalni vid

PRIMJENA AKTIVNOG UČENJA ZA DETEKCIJU PNEUMONIJE NA RENDGENSKIM SLIKAMA

Seminarski rad

Ivona Pranjić

Osijek, 2026.

SADRŽAJ

1. UVOD 3

2. PREGLED PODRUČJA I PROBLEMATIKE 4

3. EKSPERIMENTALNI REZULTATI I RASPRAVA 9

ZAKLJUČAK 17

LITERATURA 18

PRILOG 1 19

PRILOG 2 20

1. UVOD

Aktivno učenje (engl. *Active Learning*) predstavlja dio strojnog učenja, odnosno općenito umjetne inteligencije. Ključna ideja je da će – ako se algoritmu učenja dopusti da sam bira podatke iz kojih uči, odnosno da bude „znatiželjan“, ako se tako može reći – on postizati bolje rezultate uz manje treniranja. [1] Upravo zato, ovakav pristup strojnom učenju je vrlo pogodan u situacijama gdje su podaci za treniranje i izgradnju modela strojnog učenja teže dostupni, neoznačeni su i/ili je njihovo označavanje skupo te zahtijeva stručnjaka iz relevantnog područja. Primarni cilj istraživanja u ovom radu upravo spada u medicinsko područje, koje je vrlo izazovno u vidu javno dostupnih, kvalitetnih podataka za izgradnju modela, posebno sa fokusom na označenost dostupnih podataka. Također, problem koji se nastoji riješiti prvobitno se odnosi na olakšavanje posla radiologa, te lakšem dobivanju pravilne dijagnoze nakon pregleda rendgenskih slika pluća.

2. PREGLED PODRUČJA I PROBLEMATIKE

2.1. ŠTO JE AKTIVNO UČENJE?

Kao što je rečeno u uvodu, aktivno učenje predstavlja dio strojnog učenja, gdje se koristi „znatiželja“ algoritma učenja kao svojstvo modela s ciljem smanjenja potrebe za velikom količinom označenih podataka. Osnovna ideja ovog pristupa odnosi se na to da općenito za potrebe dobre performanse bilo kojeg sustava nadziranog učenja, potrebno je isti trenirati na stotinama, tisućama označenih instanci. [1] Ponekad oznake podataka nisu skupe, te ne zahtijevaju specijalizirane stručnjake za svoje označavanje, npr. oznake spam poruka koje korisnik sam može označiti kao neželjenu poštu ili ocjena smještaja na aplikacijama za iznajmljivanje i sl. U navedenim slučajevima sami korisnici pridaju oznake instancama besplatno, dok kod specifičnijih zadataka nadziranog učenja, potrebne označene instance, odnosno podaci su veoma teški, skupi ili je potrebno jako puno vremena za njihovo označavanje. [1] Sami sustavi aktivnog učenja pokušavaju riješiti problem nedostatka označenih podataka tako što odabiru neoznačene primjere i traže da ih označi stručna osoba (npr. radiolog, prevoditelj, znanstvenik itd.).

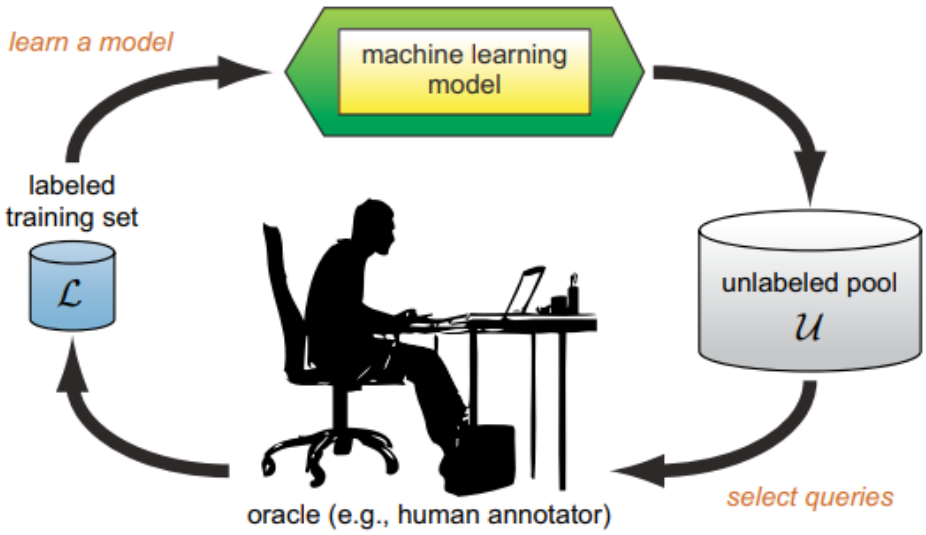

Slika 1 Proces metode aktivnog učenja

Princip se temelji na sljedećem postupku: učenik (model) može započeti s malim brojem primjera u označenom skupu za treniranje L, zatim zatražiti oznake za jedan ili više pažljivo odabranih primjera, učiti na temelju dobivenih odgovora i potom iskoristiti novo stečeno znanje kako bi odlučio koje će primjere zatražiti za označavanje. [1] Nakon što se postavi upit, algoritam učenja obično ne uvodi nikakve dodatne pretpostavke. Novi označeni primjer

jednostavno se dodaje u skup L, a model potom nastavlja učiti na standardan način, kao u klasičnom nadziranom učenju. [1]

2.2. KLASIFIKACIJA PRISTUPA AL PROBLEMU

Problemima aktivnog učenja moguće je pristupiti i rješavati na različite načine. Do sada se u teoriji i praksi koriste većinom:

1. Sinteza upita o članstvu (engl. *Membership Query Synthesis*)
2. Selektivno uzorkovanje temeljeno na toku podataka (engl. *Stream-based Selective Sampling*)
3. Uzorkovanje temeljeno na skupu podataka (engl. *Pool-based Sampling*)

Sinteza upita o članstvu predstavlja najraniji i veoma teoretski oblik aktivnog učenja. Zasniva se na tome da algoritam ne bira slike iz postojeće baze podataka, već on sam generira (stvara) potpuno novi, umjetni primjer (npr. sliku ili skup značajki) i pita stručnjaka „kojoj klasi bi ovo pripadalo?“. Problem kod ovakvog pristupa za rješavanje konkretno medicinskih problema leži u tome što generirane slike često izgledaju kao šum, nisu dovoljno realistične ili ljudskom oku (stručnjaku, npr. radiologu) nemaju smisla, pa ih je vrlo teško označiti. [1]

Selektivno uzorkovanje temeljeno na toku podataka znači da sustav dobiva jedan po jedan neoznačeni podatak kao na traci u pogonu. Za svaki podatak algoritam mora odmah odlučiti koliko mu je informativan te hoće li ga zbog toga slati stručnjaku na označavanje ili će biti odbačen. Upravo zbog takvog rada „kao u pogonu“, ovakav pristup aktivnom učenju pogodan je za korištenje kod sustava koji moraju učiti u stvarnom vremenu, gdje nema vremena ili memorije da se pohrane svi podaci odjednom.

Metoda koja se koristi u ovom radu kroz sam eksperimentalni dio jest uzorkovanje temeljeno na skupu podataka i najčešća je u današnjem modernom strojnom učenju. Njezina ideja leži u tome da se pretpostavlja da postoji veliki „bazen“, odnosno skup neoznačenih podataka. Algoritam pregledava cijeli skup, ocjenjuje informativnost za svaku sliku na temelju odabranog kriterija (npr. nesigurnost) te ih rangira. Naposljetku se uzima određeni broj podataka, odnosno slika s najvećom nesigurnošću te ih se šalje na označavanje. Upravo ovakav pristup aktivnom učenju jest standard za klasifikaciju medicinskih slika gdje već imamo prikupljene baze podataka, ali nemamo dovoljno vremena/resursa za njihovo stručno označavanje. [1]

Osim prethodnog načina koji se obradio u okviru aktivnog učenja, za usporedbu je obrađeno i tzv. nasumično uzorkovanje (engl. *Random Sampling*). Ovakav pristup temelji se, kako i sam

naziv kaže, na nasumičnosti odabira podataka koje se označava. Upravo usporedbom navedenih dvaju pristupa može se vidjeti koliko je modelu važno uči li na slikama koje su mu najteže za klasificirati ili mu je pak dovoljno da dobije bilo koju sliku iz skupa koja će biti označena.

2.3. DUBOKO AKTIVNO UČENJE

Duboke neuronske mreže (DNN) postale su ključni alat u rješavanju kompleksnih zadataka strojnog učenja. Iako postižu izvrsne rezultate, njihovo treniranje zahtijeva enormne količine označenih podataka, čije je prikupljanje i označavanje iznimno skupo i dugotrajno. Na križanju između aktivnog učenja i dubokog učenja javlja se upravo pojam dubokog aktivnog učenja – DAL (engl. *Deep Active Learning*), koje rješava problem troškova označavanja podataka i omogućuje postizanje visokih performansi modela. DAL se uspješno primjenjuje u različitim domenama, npr. prepoznavanja imenovanih entiteta, detekcije objekata te napredne analize i segmentacije medicinskih slika. S druge strane, prijelaz s klasičnih metoda aktivnog učenja na korištenje modela dubokog učenja nosi i svoje specifične izazove. Za razliku od klasičnog strojnog učenja gdje su značajke fiksne i unaprijed definirane, u dubokom učenju model istovremeno uči i značajke i klasifikaciju. To znači da se reprezentacije podataka dinamički mijenjaju tijekom svakog ciklusa aktivnog učenja, što zahtijeva ponovno izračunavanje sličnosti među podacima u svakoj novoj iteraciji. Također, duboke neuronske mreže često daju statistički vrlo samouvjerena predviđanja čak i kada griješe. Zbog toga procjena nesigurnosti neoznačenih podataka se može pokazati nepouzdanom, što zahtijeva pažljiv odabir strategije uzorkovanja. Suvremena istraživanja u području naglašavaju važnost objektivne usporedbe različitih DAL algoritama na kompleksnim zadacima. Poseban naglasak stavlja se na medicinsku analizu slika, gdje se istražuje utjecaj veličine *batcha* i broja epoha treniranja na konačnu učinkovitost modela. Razvoj i proširivanje okvira za DAL omogućuje lakšu primjenu navedenih metoda na specifične medicinske probleme, čime se upravo olakšava dizajn algoritama koji su robusni na šum i specifičnosti podataka. [2]

2.4. AKTIVNO UČENJE U MEDICINSKOJ RADIOLOGIJI

Primjena strojnog i dubokog učenja, pa tako i metoda aktivnog učenja postale su vrlo aktualne u posljednjim godinama. Njihovim razvojem omogućuje se integracija umjetne inteligencije u različite sfere ljudskih života – od tehnike, industrije, zabave pa sve do zdravlja i medicine. Ono što medicinsku primjenu ovakvih alata razlikuje od primjerice njihove primjene za razonodu jest upravo specifičnost samih medicinskih podataka. Za razliku od recimo prepoznavanja i klasifikacije mačaka na slikama, gdje svatko može označiti i pridati labele slikama, medicinske

slike ipak zahtijevaju radiologa odnosno stručnjaka s godinama iskustva. Osim toga, znanstveni radovi su pokazali kako je rijetkost podataka koji posjeduju visoku kvalitetu i točne oznake osobito velika prepreka u području. [3] Njihovu nedostupnost na prvom mjestu stvara privatnost pacijenata i politika zaštite zdravstvenih ustanova, kao i nedovoljno poznavanje uzoraka rijetkih i teže dijagnosticiranih bolesti.

U relativno nedavnom jeku pandemije COVID-19, rendgensko snimanje prsnog koša nametnulo se kao jedna od ključnih dijagnostičkih metoda otkrivanja pneumonije uzrokovane korona virusom. Njezina široka dostupnost, niska cijena i brzina dobivanja rezultata, osobito u područjima s ograničenim resursima su samo od nekih prednosti. Međutim, brza narav širenja virusa često nadilazi kapacitete sustava za ručnu obradu i analizu snimaka, što se upravo pokazalo u godinama nedavne pandemije. Zbog tih manjkavosti, bilo je potrebno pronaći način kako olakšati posao radiolozima i doktorima, gdje se umjetna inteligencija, kao područje u punom razvoju, pokazala kao izvrstan izbor. Iako su metode dubokog učenja, poput konvolucijskih neuronskih mreža (engl. *Convolutional Neural Network*, CNN), pokazale vrhunske rezultate u automatiziranoj obradi medicinskih slika, njihova primjena u stvarnom vremenu suočava se s kritičnim preprekama kao što je nedostatak sveobuhvatnih podataka i skupova učenja te preopterećenost medicinskih stručnjaka za označavanje navedenih snimaka. U tom kontekstu, aktivno učenje se pojavljuje kao „most“ koji povezuje potrebu za preciznošću dubokog učenja i ograničene resurse za označavanje. Umjesto čekanja na stvaranje golemih baza podataka, AL omogućuje modelu da u interakciji s radiolozima dinamično bira najinformativnije i najizazovnije snimke. [4] Ovakav pristup, koji je upravo obrađen u radu, rješava prethodne probleme, jer fokusira pažnju modela na granične slučajeve koji su ključni za transparentna i točna predviđanja u kriznim situacijama. Time se postiže upravo brža implementacija dijagnostičkih alata uz minimalno opterećenje medicinskog osoblja, što je bilo od presudne važnosti u fazama pandemije.

2.5. TRENUTNI IZAZOVI U PODRUČJU

Iako su rezultati primjene aktivnog učenja u radiologiji i medicini ohrabrujući, suvremena istraživanja ukazuju na nekoliko ključnih izazova koji ograničavaju puni potencijal sustava u kliničkoj praksi. Jedan od najvećih izazova jest izrazita nebalansiranost podataka, gdje broj zdravih uzoraka često višestruko nadmašuje broj patoloških nalaza. Istraživanja pokazuju da uvođenje Bayesovih metoda, poput Gaussovih procesa može pružiti stabilnije procjene nesigurnosti koje su otpornije na ovaj problem. Ovakvi pristupi omogućuju postizanje visoke

točnosti koristeći svega 10% ukupno dostupnih označenih podataka, što je od presudne važnosti kod specifičnih dijagnoza poput COVID-19. [5]

Drugi značajan izazov je nedostatak jedinstvenih okvira za objektivnu evaluaciju metoda dubokog učenja. Budući da takve neuronske mreže uče reprezentacije značajki dinamički tijekom procesa, rezultati često ovise o faktorima koji nisu izravno vezani uz samu strategiju uzorkovanja, već uz postavke treninga. Neki od ključnih faktora s izravnim utjecajem su *batch size* i broj epoha treniranja. [6]

Novi trendovi nastoje integrirati aktivno učenje s nenadziranim učenjem značajki. Cilj je omogućiti modelu da samostalno „shvati“ vizualne obrasce iz neoznačenih podataka prije nego što krene u selektivno označavanje najinformativnijih uzoraka uz pomoć stručnjaka. [5]

Konačno, ističe se važnost provođenja eksperimenta pod strogo kontroliranim i poštenim uvjetima usporedbe. Bez izravne usporedbe AL strategija s nasumičnim uzorkovanjem pod identičnim parametrima (arhitektura mreže, optimizator, funkcija gubitka), nemoguće je precizno utvrditi stvarnu uštedu u troškovima označavanja. [6] Upravo ovakva usporedba i eksperiment obrađeni su u sljedećim poglavljima rada.

3. EKSPERIMENTALNI REZULTATI I RASPRAVA

3.1. KORIŠTENE TEHNOLOGIJE I OKRUŽENJE

Za potrebe izrade eksperimentalnog dijela rada korišten je programski jezik Python u kombinaciji s radnim okvirom PyTorch, koji omogućuje fleksibilnu izgradnju i treniranje dubokih neuronskih mreža. Eksperimenti su provedeni unutar Google Colab okruženja, čime je osiguran pristup naprednijim grafičkim procesorskim jedinicama (GPU) nužnim za ubrzanje procesa učenja modela. Kao osnovna arhitektura korišten je poznati pretrenirani model VGG16 kroz metodu prijenosnog učenja, prilagođen zadatku binarne klasifikacije rendgenskih snimaka.

3.2. OPIS EKSPERIMENTA

Na samom početku eksperimenta bilo je potrebno osigurati pristup bazi slika. Skup podataka preuzet je s Kagglea pod nazivom „Chest X-Ray Images (Pneumonia)“. [7] Skup se sastoji od 3 direktorija koji su prethodno podijeljeni na trening, test i validacijski dio. Za potrebe ovog zadatka korišteni su samo trening i test skupovi. Također, bilo je potrebno napraviti vizualnu usporedbu te usporedbu u broju podataka s kojima se radi. Unutar trening skupa, broj slika s oznakom 'normal' je 1341, dok onih s oznakom 'pneumonia' je 3875. Što se tiče skupa za testiranje, slika zdravih pluća je 234, a onih s dijagnosticiranom pneumonijom 390.

Slika 2 Nasumični uzorci slika zdravih pluća (normal)

Slika 3 Nasumični uzorci slika pluća s upalom (pneumonia)

Nakon pregleda skupa, dolazi se do zaključka kako je skup u disbalansu, prevladavajući slikama s dijagnosticiranom upalom pluća, dok je zdravih uzoraka manje. Ovaj podatak vrlo je važan za daljnji tijek eksperimenta te konačno za donošenje zaključka. Također, vrlo je važno napomenuti kako za potrebe eksperimenta i aktivnog učenja, korišteni skup podataka se promatrao kao da nije označen, a u dijelu u kojem model traži oznaku od radiologa se ponovno pridodaju oznake slikama.

Izrada osnovnog modela korištenjem prijenosnog učenja (engl. *Transfer Learning*) pomoću VGG16 arhitekture bila je sljedeći korak. Upravo ovaj dio predstavlja nultu točku koja služi kao standard prema kojemu se nastavlja daljnji tok i usporedba metoda. On predstavlja osnovno znanje koje model može steći bez ikakve pametne selekcije podataka. U kontekstu ovog eksperimenta, korištena je prva verzija VGG16 mreže koja je trenirana na malom, inicijalnom skupu. Svrha je da se utvrdi kolika je preciznost modela kada ga treniramo i testiramo sa samo nekoliko primjera. Bez ovog koraka kasnije bi bilo teško uočiti je li promjena u metrikama rezultat aktivnog učenja ili postoji drugi razlog. Uz prilagodbu arhitekture mreže, koja za ove potrebe u zadnjem sloju klasificira u samo dvije klase, umjesto originalnih mnogobrojnih klasa, postignuti su prvi rezultati.

Osim pripreme *baseline* modela, vrlo važan korak kod ovakvih zadataka jest normalizacija i priprema podataka. VGG16 zahtijeva fiksnu ulaznu veličinu (224x224), što je ostvareno korištenjem funkcije `resize()`. Osim toga, vrlo je važno skalirane podatke pretvoriti u oblik razumljiv računalu, odnosno u oblik PyTorch tenzora, što je postignuto funkcijom `ToTensor()`. Budući da je korišten pretrenirani VGG16, slike je potrebno normalizirati na isti način kao i one na kojima je model originalno učen kako bi značajke koje model prepoznaje imale smisla (funkcija `normalize()`).

„Srce“ eksperimenta krije se u sljedećem koraku, gdje je postignuto pretvaranje statičkog modela u dinamični sustav koji „zna što ne zna“. Model ne traži slike koje su mu jasne, već one koje se nalaze na samoj granici između dvije klase. Funkcijom `get_uncertain_samples()` definiran je kriterij po kojem model bira podatke – služi kao mehanizam za selekciju najinformativnijih uzoraka. Sve slike iz neoznačenog skupa se rangiraju prema izračunatoj nesigurnosti. Korištenjem `sort()` funkcije na vrh liste stavljaju se slike s najmanjom nesigurnošću. Upravo one postaju „pitanja“ koja model postavlja stručnjaku, odnosno daje ih na označavanje.

Proces učenja osmišljen je kao dinamičan, iterativni ciklus koji simulira postupno prikupljanje znanja. Eksperiment započinje s inicijalnim skupom od svega 10 nasumično odabranih i označenih slika rendgena, što predstavlja polaznu točku modela. Kroz deset uzastopnih iteracija, u svakom koraku dodajemo točno deset novih uzoraka, čime se provodi proces inkrementalnog učenja. Ključni detalj u ovoj petlji je strogo upravljanje indeksima podataka – jednom odabrani uzorci automatski se miču iz skupa dostupnih neoznačenih podataka i premještaju u skup za treniranje, čime se sprječava redundancija i osigurava da model u svakom krugu obrađuje isključivo nove informacije.

Kako bi se osigurala znanstvena objektivnost i potvrdila učinkovitost aktivnog učenja, provedena je metodologija poštene usporedbe. To je postignuto uvođenjem dodatnog dijela eksperimenta koji je koristio nasumično uzorkovanje pod identičnim uvjetima. Oba su modela koristila istu arhitekturu (VGG16), isti broj epoha po iteraciji te identičan broj dodanih slika. Ovakav pristup eliminira utjecaj vanjskih parametara, izolirajući strategiju odabira uzoraka kao jedinu varijablu koja utječe na razliku u performansama.

Uspješnost oba pristupa mjerena je kroz sustav preciznih metrika s posebnim naglaskom na medicinski kontekst. Uz točnost i funkciju gubitka, evaluacija se primarno fokusirala na preciznost i odziv. U radiologiji je odziv ključna stavka jer minimizira vjerojatnost propuštanja bolesnih pacijenata, dok F1 mjera služi kao ključni indikator ravnoteže te dvije metrike, pružajući najrealniju sliku o robusnosti modela na nebalansiranim medicinskim podacima.

3.3. ANALIZA REZULTATA

Nakon provedenih iteracija eksperimenta, u ovom podpoglavlju analiziramo dobivene rezultate kroz usporedbu metrika uspješnosti te pripadajućih grafova. Središnji fokus analize je utvrđivanje razlike u brzini učenja i kvaliteti predviđanja između modela koji koristi aktivno

učenje i onog koji se oslanja na nasumično uzorkovanje. Detaljan prikaz svih numeričkih vrijednosti metrika kroz deset iteracija za oba modela nalazi se u Prilogu 1.

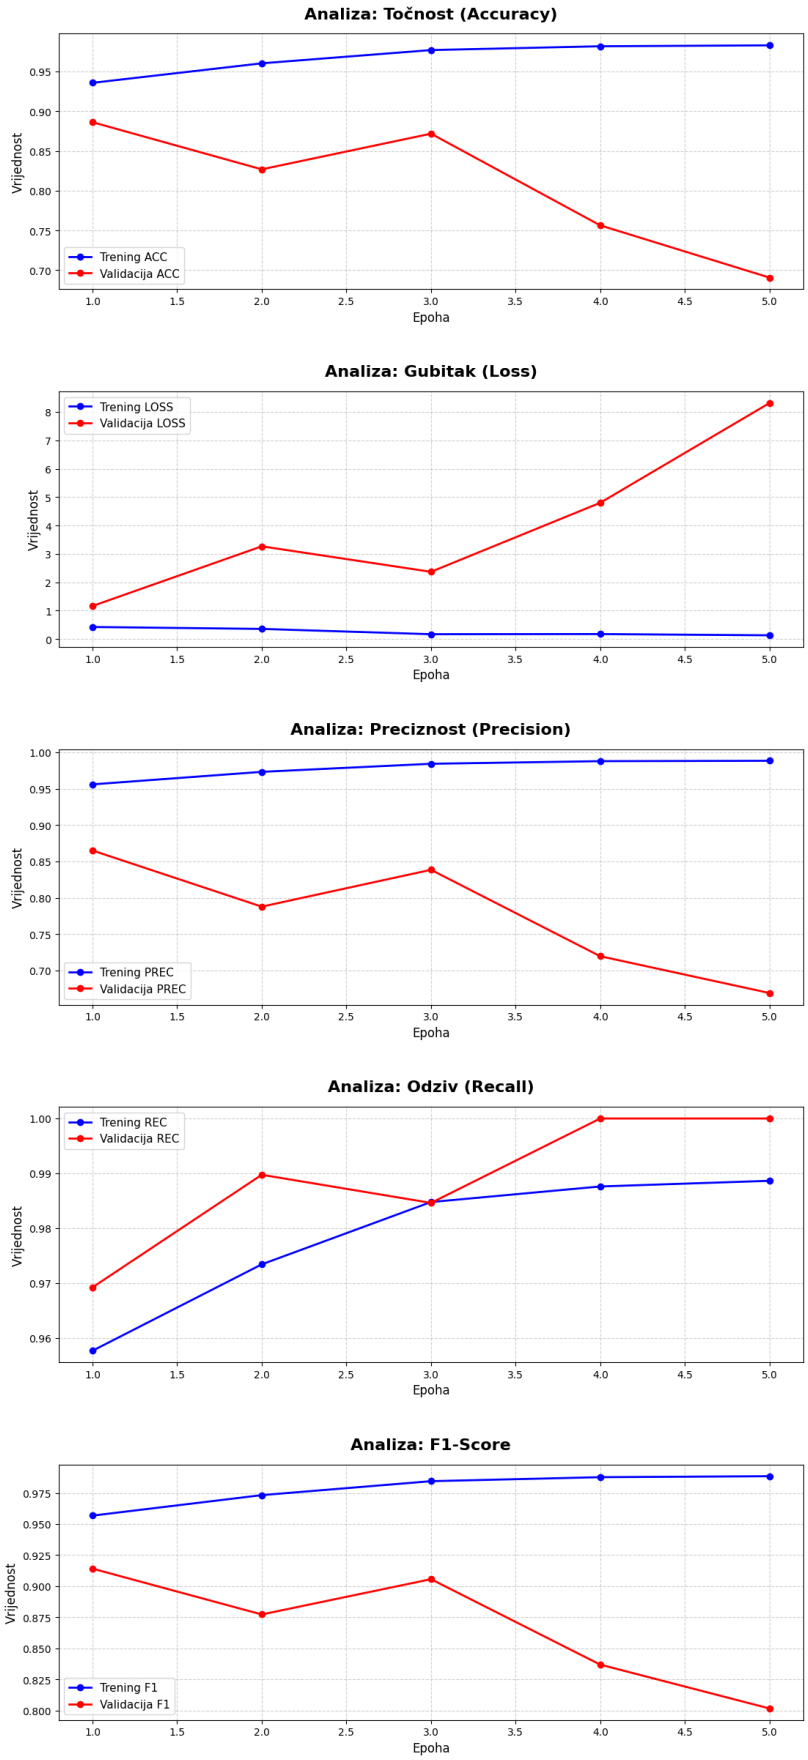

Slika 4 Vizualna reprezentacija rezultata baseline modela

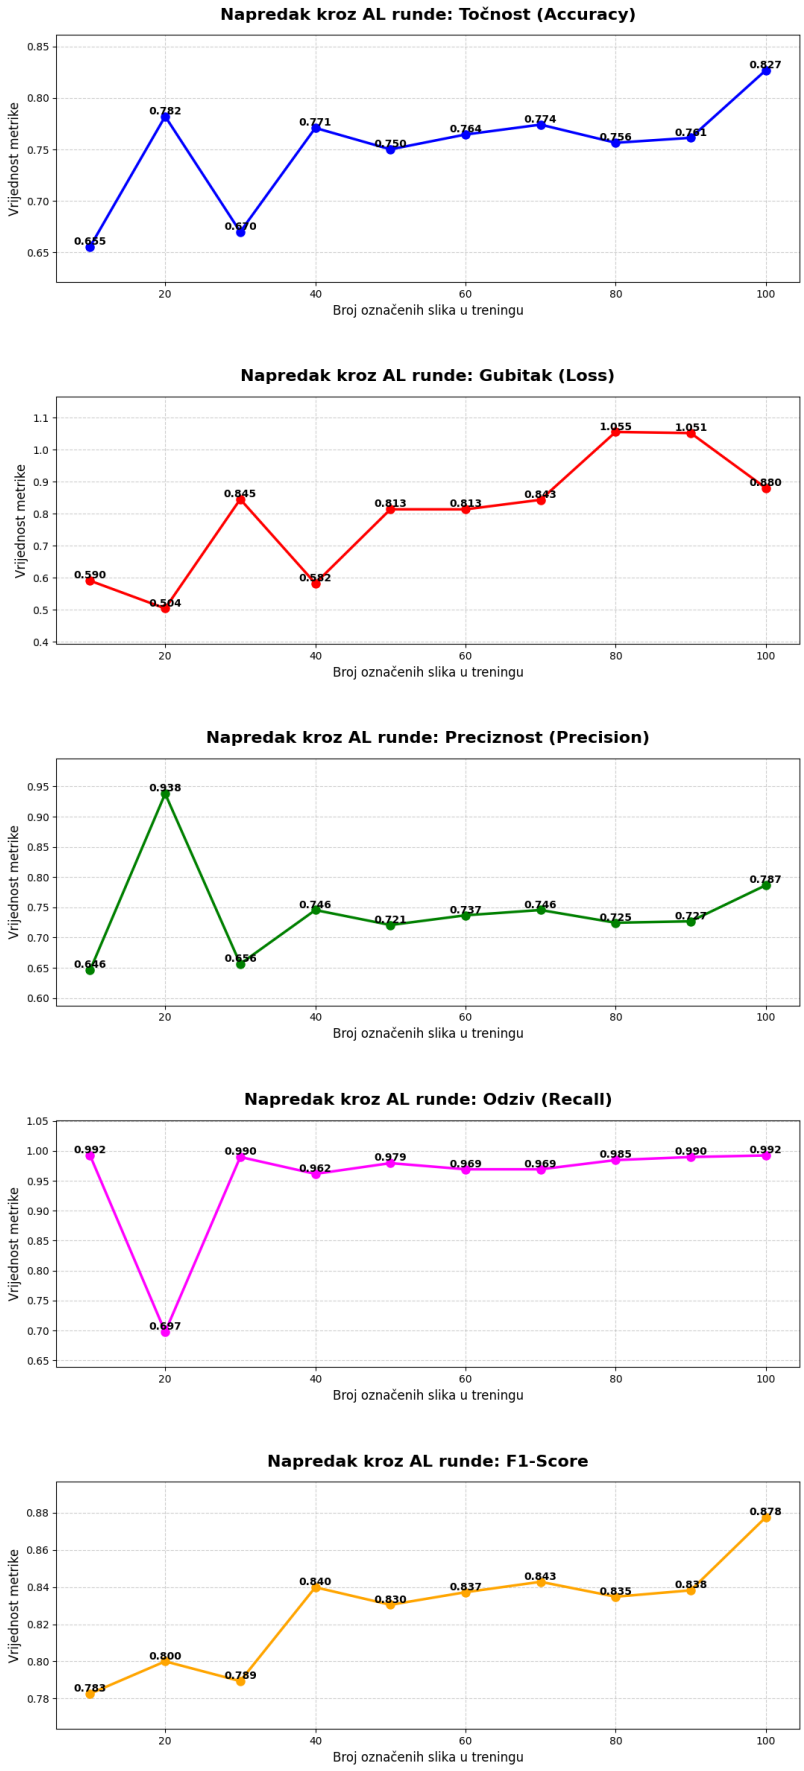

Slika 5 Vizualna reprezentacija AL modela

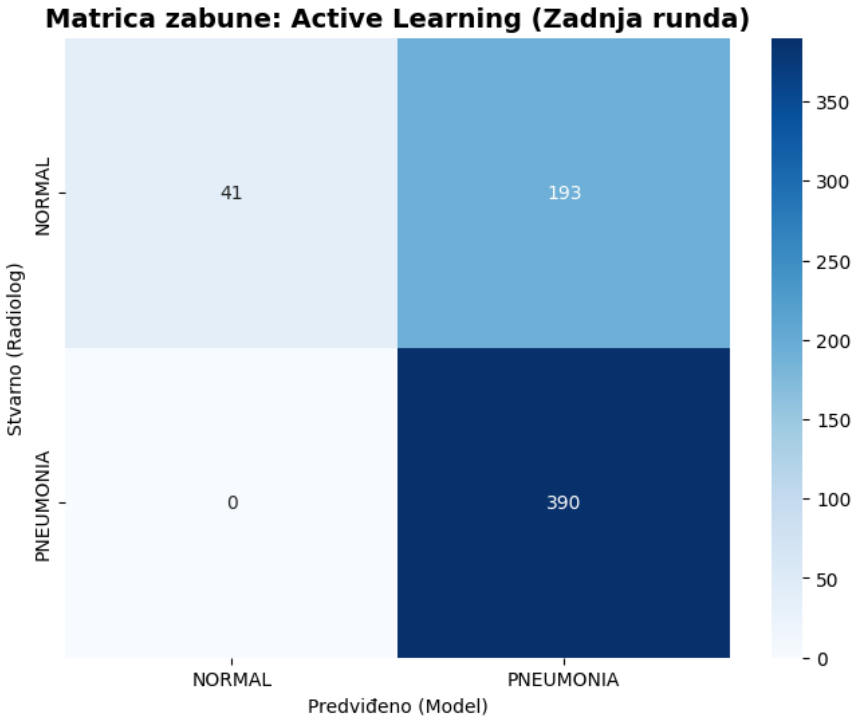

Slika 6 Matrica zabune AL modela

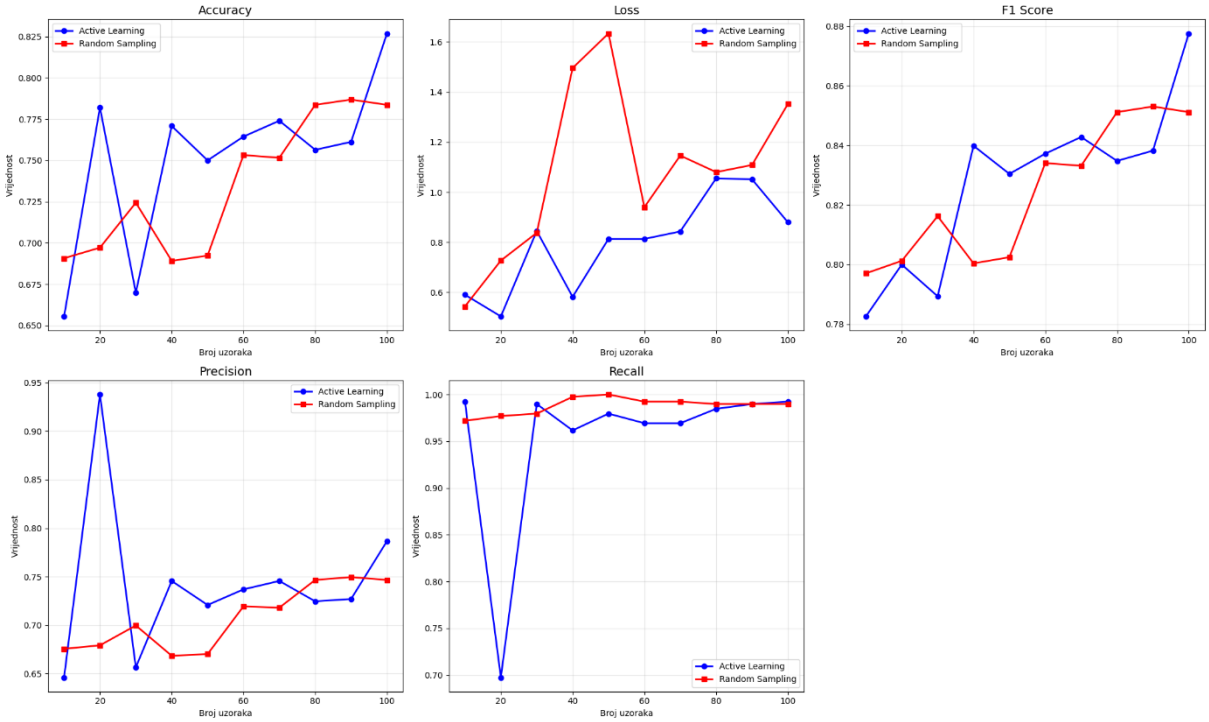

Slika 7 Usporedni grafovi AL i random sampling modela

Na posljednjoj slici prikazana je usporedba performansi modela kroz deset iteracija učenja. Plava krivulja predstavlja model koji koristi aktivno učenje, dok crvena prikazuje nasumično

uzorkovanje. Primjetno je da plava krivulja, kod usporedbe točnosti (engl. *Accuracy*) i gubitka (engl. *Loss*), brže raste u ranim fazama eksperimenta. Već pri manjem broj uzoraka aktivno učenje postiže točnost koju nasumično uzorkovanje doseže znatno kasnije. Istovremeno, graf gubitka za AL brže opada i pokazuje stabilniji trend, što sugerira da model brže konvergira prema optimalnim težinama odabirom informativnijih primjera.

F1 kao mjera koja balansira preciznost (engl. *Precision*) i odziv (engl. *Recall*), kod AL modela pokazuje dosljednu nadmoć. Dok crvena krivulja pokazuje veće oscilacije, plava krivulja je stabilnija i viša, što dokazuje da je model koji pametnije bira podatke robusniji, pogotovo u uvjetima ograničenog broja označenih slika.

Posebno je značajna razlika u grafu odziva. U medicinskoj dijagnostici, visoki odziv je ključan jer on garantira da će sustav prepoznati bolesne pacijente. AL model, iako početno s visokom oscilacijom, doseže visoku razinu odziva te ju kasnije održava, kao i usporedni model s nasumičnim uzorkovanjem.

ZAKLJUČAK

U ovom radu bilo je potrebno provjeriti koliko je dobra upotreba metode aktivnog učenja u detekciji pneumonije na slikama rendgena pluća, te istu usporediti s učenjem mreže na nasumično uzorkovanim slikama. Kroz eksperimentalni dio i njegovu analizu, jasno je uočeno kako aktivno učenje doista potvrđuje svoje prednosti u uporabi upravo u kompleksnom području medicinske radiologije. S rezultatima kao i teorijskom podlogom je utvrđeno kako bi se u budućnosti mogli razvijati sustavi koji od liječnika traže pomoć samo za „teške“ slučajeve, čime se smanjuje zamor liječnika i ubrzava sam proces uspostavljanja dijagnoze. Kombinacija prijenosnog i aktivnog učenja u konstrukciji neuronske mreže bila je ključna za postizanje visoke točnosti, posebno kontinuiranog odziva i drugih metrika, s vrlo malo podataka (svega 100 označenih slika). S obzirom da rezultati dakako nisu savršeni, predlaže se u budućnosti testirati i druge strategije nesigurnosti ili veće skupove podataka. Također, bilo bi zanimljivo vidjeti kako bi se model ponašao na slikama s više različitih patologija, a ne samo pneumonijom. Naposljetku, ovaj projekt dokazuje da u dobu ogromne količine informacija i različitih rješenja za obradu istih, fokus ne mora uvijek stavljati na samu brojnost podataka, već i na njihovu kvalitetu i pametan odabir.

LITERATURA

[1] Burr Settles, Active Learning Literature Survey, Computer Sciences Technical Report 1648, University of Wisconsin – Madison, 2009. https://burrsettles.com/pub/settles.activelearning.pdf zadnji pristup: 10.3.2026.

[2] Biswas, A., Al Nasim, A., Ali, S., Hossain, I., Ullah, A. , Talukder, S., Active learning on medical image, 31.8.2024. https://arxiv.org/pdf/2306.01827 zadnji pristup: 25.3.2026.

[3] Roy M., G., Zandehshahvar, M., Assen van, M., Kittisut, N., Peters, K., N. De Cecco, C., Adibi, A., Deep Active Learning for Lung Disease Severity Classification from Chest X-rays: Learning with Less Dana in the Presence of Class Imbalance, 2025. https://link.springer.com/content/pdf/10.1007/s10278-025-01752-8.pdf zadnji pristup: 26.3.2026.

[4] Alghamdi, S., H., Amoudi, G., Elhag, S., Saeedi, K., Nasser, J., Deep Learning Approaches for Deetecting COVID-19 From Chest X-ray Images: A Survey, King Abdulaziz University, Jeddah, Saudi Arabia, 2021. https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=9335581 zadnji pristup: 26.3.2026.

[5] Hao, H., Hankyu, M., Didari, S., Oh Woo, J., Bangert, P., Highly Efficient Representation and Active Learning Framework and Its Application to Imbalanced Medical Image Classification, Samsung SDS Research America, 35th Conference on Neural Information Processing Systems, Sydney, Australia, 2021. https://arxiv.org/pdf/2103.05109v4 zadnji pristup: 26.3.2026.

[6] Zhan, X., Wang, Q., Huang, K.-H., Xiong, H., Dou, D., Chan, A.B., A Comparative Survey of Deep Active Learning, 2022. https://arxiv.org/pdf/2203.13450 zadnji pristup: 26.3.2026.

[7] Chest X-Ray Images (Pneumonia), Kaggle https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia posljednji pristup: 10.2.2025.

PRILOG 1

SLIKE	AL_Acc	Rand_Acc	AL_Rec	Rand_Rec	AL_F1	Rand_F1
10	0.655449	0.690705	0.992308	0.971795	0.782609	0.797056
20	0.78205	0.697115	0.697436	0.976923	0.800000	0.801262
30	0.669872	0.724359	0.989744	0.979487	0.789366	0.816239
40	0.770833	0.689103	0.961538	0.997436	0.839866	0.800412
50	0.750000	0.692308	0.979487	1.00000	0.830435	0.802469
60	0.764423	0.753205	0.969231	0.992308	0.837209	0.834052
70	0.774038	0.751603	0.969231	0.992308	0.842809	0.833154
80	0.756410	0.783654	0.984615	0.989744	0.834783	0.85115
90	0.761218	0.786859	0.989744	0.989744	0.838219	0.853039
100	0.826923	0.783654	0.992308	0.989744	0.877551	0.851158

Tablica 1Tablični prikaz rezultata eksperimenta

PRILOG 2

Poveznica na originalni programski kod i replikaciju eksperimenta:

https://colab.research.google.com/drive/1pUwzNZyrKn3oheruNbkOzbNNRQJwGLVQ#scrollTo=ZGmyf6oRUMMq